

结合迁移学习与深度卷积网络的心电分类研究

查雪帆¹, 杨丰^{1,2}, 吴保南¹, 刘颖¹, 袁绍锋^{1,2}

1. 南方医科大学生物医学工程学院, 广东 广州 510515; 2. 南方医科大学广东省医学图像处理重点实验室, 广东 广州 510515

【摘要】为解决一维深度卷积网络(1D-DCNN)在心电分类方面存在的多类疾病识别不准、难以提取最佳特征等问题,提出一种结合迁移学习与二维深度卷积网络(2D-DCNN)直接识别心电图像的方法。首先,截取R波前后75 ms内的心电信号,并将一维心电电压信号转化为二维灰度图像信号。接着,构建2D-DCNN对心电节拍样本进行分类训练,权值初始化采用在ImageNet大规模图像数据集上进行预训练的AlexNet参数值。本文提出方法在MIT-BIH心电数据库上进行性能验证,其准确率达到98%,并在不同信噪比下保持较高的准确率,证明了所述模型在心电分类上具有良好的鲁棒性。为了验证2D-DCNN的识别性能,实验部分与采用不同激活函数的1D-DCNN、近些年性能较好的深度学习方法进行比较。量化结果表明,结合迁移学习和2D-DCNN方法,比最优1D-DCNN算法,其准确率提升2%、敏感度提升0.6%、特异性提高4%;在二分类与多分类任务中,均好于现有的其他算法。

【关键词】心电节拍分类; 迁移学习; 深度学习; 二维深度卷积网络; 一维深度卷积网络; ImageNet数据集

【中图分类号】R318

【文献标志码】A

【文章编号】1005-202X(2018)11-1307-06

ECG classification based on transfer learning and deep convolution neural network

ZHA Xuefan¹, YANG Feng^{1,2}, WU Yu'nan¹, LIU Ying¹, YUAN Shaofeng^{1,2}

1. School of Biomedical Engineering, Southern Medical University, Guangzhou 510515, China; 2. Guangdong Provincial Key Laboratory of Medical Image Processing, Southern Medical University, Guangzhou 510515, China

Abstract: One-dimensional deep convolution neural networks (1D-DCNN) for electrocardiogram (ECG) classification shows limitations in identifying various diseases and extracting the best morphological features. Herein, a method combining transfer learning and two-dimensional deep convolution neural network (2D-DCNN), AlexNet, is proposed to identify ECG images directly. Firstly, the ECG signals within the 75 ms before and after R wave were intercepted, and one-dimensional ECG voltage signals were converted into two-dimensional grayscale image signals. Then, a 2D-DCNN based on AlexNet was established to classify the ECG heartbeat samples. The weights were initialized by parameters which were pre-trained on Alexnet using a large-scale dataset ImageNet. The proposed method achieved an accuracy of 98% on the MIT-BIH arrhythmia database, and maintained a high accuracy at different signal-to-noise ratios, which verified the good robustness of the proposed method in ECG classification. The proposed method was also compared with 1D-DCNN using different activation functions and other deep learning methods with favorable performances to evaluate the performance of 2D-DCNN. The quantitative results demonstrated that compared with the optimal 1D-DCNN, the proposed method combining transfer learning with 2D-DCNN improves the accuracy rate, sensitivity and specificity by 2%, 0.6% and 4%, respectively, and that the proposed algorithm is better than other existing algorithms in both binary/multi-class classification tasks.

Keywords: electrocardiogram heartbeat classification; transfer learning; deep learning; two-dimensional deep convolution neural network; one-dimensional deep convolution neural network; ImageNet dataset

前言

目前,心电图(Electrocardiogram, ECG)是临床医生诊断心脏疾病的主要方法^[1-2]。但准确的心电数据识读需要经验丰富的医生,并且人工诊断往往无法实时监测异常心电波形;同时在判读过程中诊断误差难以避免^[3-4]。因此,如何利用计算机自动识别心电信号成为研究的热点。传统的心电分类方法依赖

【收稿日期】2018-06-28

【基金项目】国家自然科学基金(61771233, 61271155)

【作者简介】查雪帆,研究方向:机器学习与医学图像处理, E-mail: xuefanzha.smu@gmail.com

【通信作者】杨丰,教授,博士生导师,研究方向:模式识别、机器学习、医学图像处理、医学信号处理, E-mail: yangf@smu.edu.cn

各种算法来手动提取和选择合适的形态特征。Pan-Tompkins^[5]算法通过自适应阈值和搜寻等过程对QRS波群进行检测。黄碧莹等^[6]利用R波峰值与R-R间期信息,提高了心电信号的检测准确率。袁野等^[7]利用小波变换结合独立成分分析对心电信号进行降噪处理,将高频噪声与心电信号分离。但是上述算法难以针对不同病人间的心电波形选取最佳形态特征^[3-4],计算繁琐,且心电信号对噪声敏感,从而限制了心电识别的准确率。随着机器学习的发展,特征可以通过合适的模型自动提取,其效果在分类问题上优于手工设计特征^[3,8]。Kiranyaz等^[9]使用自适应一维卷积神经网络(1D Convolutional Neural Networks, 1D-CNN)对室性异位搏动及室性早搏进行识别分类,并达到了良好的检测效果。颜昊霖等^[10]提出了基于1D-CNN心电特征提取方法,提升了自动分类的精度。以上深度学习方法都将心电信号作为一维时间序列,而卷积神经网络对一维时间序列的处理效果会因为训练样本不足受到限制,比如多分类识别性能下降,受噪声干扰影响大等^[11]。

本文针对上述问题,结合迁移学习(transfer learning)^[12]和深度学习(deep learning)^[13],提出基于二维灰度图像输入的深度卷积神经网络(2D Deep Convolutional Neural Networks, 2D-DCNN)模型。该方法一方面采用ImageNet大规模图像数据集预训练的网络权值进行网络训练,缓解二维心电图图像训练样本不足的问题,另一方面利用AlexNet-like二维深

度卷积网络自动地提取心电波形特征,解决目前手工设计的波形特征对心拍的病人间差异不鲁棒的困难。

1 方法

1.1 AlexNet-like 深度卷积神经网络

AlexNet^[13]由5卷积层和3全连接层组成,与传统卷积网络^[14]相比,有如下特点:(1)线性激活函数ReLU层,增强网络的非线性映射能力,同时加快网络收敛速度;(2)Dropout层,从网络全连接层中随机丢弃某些节点,可防止网络的过拟合问题;(3)重叠的最大值池化层,避免了平均值池化对特征信息的模糊;(4)充分的数据扩充预处理,降低深度网络受过拟合影响的风险,同时增强卷积网络的鲁棒性。

本文以AlexNet卷积神经网络结构为基础,对心电数据进行训练并分类,并与基于一维电压信号输入且网络结构相同的1D-CNN进行比较。2D-DCNN AlexNet-like结构如表1所示。第1层为图像输入,其大小为 227×227 ;第2层采用32组卷积核,其大小为 7×7 ;第4层采用64组卷积核,其大小为 5×5 ;第6~8层均使用128组卷积核,其大小为 3×3 ;最大值池化层的窗口大小为 3×3 ,步长为2,分别设置在第3、5、9层。紧接着设置两层全连接层,其输出通道大小为1 024,每层后面都添加Dropout层。最后,使用Softmax分类器。各卷积层和全连接层均使用ReLU激活函数。

表1 本文使用的深度卷积网络结构参数

Tab.1 Structure parameters of the deep convolution network used in this research

Layer	Operation	Channel	Size	Stride	Padding	Activation
1	Input	1	-	-	-	-
2	Convolution	32	7	3	2	ReLU
3	Pooling	32	3	2	0	-
4	Convolution	64	5	1	2	ReLU
5	Pooling	64	3	2	0	-
6	Convolution	128	3	1	2	ReLU
7	Convolution	128	3	1	2	ReLU
8	Convolution	128	3	1	2	ReLU
9	Pooling	128	3	2	0	-
10	Dense	1024	-	-	-	ReLU
11	Dropout	1024	-	-	-	-
12	Dense	1024	-	-	-	ReLU
13	Dropout	1024	-	-	-	-
14	Output	2	-	-	-	Softmax

1.2 激活函数

在神经网络中,激活函数提供非线性,使得网络可拟合任意复杂函数。激活函数会影响网络学习的速率和分类准确率。常用的激活函数有 tanh, ReLU, ELU, SeLU 等,如公式(1~4)所定义。ReLU 函数的使用避免了梯度消失的问题,且计算简便,提高了运算速度^[15]。ELU 函数是对 ReLU 的改进,在输入为负数情况下依然存在输出,增强了网络抗干扰能力。最近, Klambauer^[16]在自归一化网络(Self-Normalized Neural Networks, SNN)中提出 SeLU 函数,实现了将样本分布自动归一化到零均值和单位方差。Google Brain 提出了一种新的激活函数 Swish^[17],如公式(5)所定义,该函数在深度网络中得到了比 ReLU 更好的训练结果,适用于各种大数据集。Swish 与 ReLU 的相同点是只有上界没有下界,主要区别在于 Swish 函数是单调的平滑曲线。5 种不同的激活函数如图 1 所示。为了找到适用于心电分类的最佳激活函数,本文对比了 1D-CNN 在采用不同激活函数时的心电分类准确率。上述 5 种激活函数定义如下:

$$\text{ReLU}(x) = \max(0, x) \quad (1)$$

$$\text{ELU}(x) = \begin{cases} x, & x > 0 \\ \alpha e^{-2x} - 1, & x \leq 0 \end{cases} \quad (2)$$

$$\tanh(x) = \frac{1 - e^{-2x}}{1 + e^{-2x}} \quad (3)$$

$$\text{SeLU}(x) = \lambda \begin{cases} x, & x > 0 \\ \alpha(e^{-2x} - 1), & x \leq 0 \end{cases} \quad (4)$$

$$\text{Swish}(x) = \frac{x}{1 + e^{-x}} \quad (5)$$

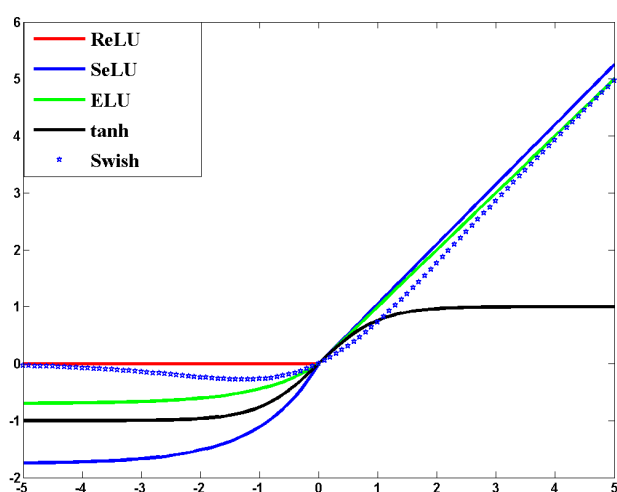


图1 不同的激活函数

Fig.1 Different activation functions

1.3 基于 ImageNet 对网络进行迁移学习

迁移学习主要解决用于分类的目标数据集较小

的问题,可以在有效抑制过拟合的情况下,训练目标网络。网络首先在一个基础数据集上训练,经过预训练的网络需要将目标数据集与已有特征相结合,即用目标数据集进行微调,将其输入基础网络进行训练以调整网络参数。迁移学习在分类的目标数据集有限的情况下起到提升网络分类准确率的作用^[12]。

本文使用二维心电图图像输入的卷积神经网络,由于数据维度较大,网络存在过拟合问题。为了抑制这一问题,使用经过大规模图像数据集 ImageNet 训练后的权值对网络进行迁移学习。ImageNet 是图像识别领域的大规模数据库,含有超过 1 500 万张、共 22 000 多类带标签的高分辨率图像^[18]。在之前的研究中已经证明:在有标注的大规模图像集上进行训练的深度神经网络具有较好的图像特征和良好的泛化能力,将其参数值迁移到其它的图像分类任务中往往得到较好的分类效果。本文采用在 ImageNet 数据集上进行预训练的 AlexNet 参数值对 AlexNet-like 网络进行权值初始化,并通过 MIT-BIH 数据集的训练进行分类器微调,来比较预训练处理对网络分类效果的影响。

1.4 一维信号到二维图像的转换

一个心动周期的波形反映了心室收缩过程中心肌细胞的电活动,疾病的诊断是基于心动周期内完整的 QRS 波形态特征。本文以此作为依据,以 R 波标注前后 75 ms 内的信号为 QRS 波群,将一个心动周期分割出来作为样本,记录每个心动周期对应的电压幅值,建立了以电压信号形式输入 1D-CNN。为了使神经网络的输入大小一致,对一维电压信号进行补 0 处理,使其成为长度均为 820 的序列。

将截取到的心电幅值信号映射在二维空间中,建立灰度化后的心电图图像样本,送入 2D-DCNN 进行学习。如图 2 所示为本文对心电信号的处理流程图,其中非白色像素点代表截取到的 QRS 波段,白色像素点代表无信号存在。由于全连接层要求输入固定大小的特征向量,所以将心电图图像大小设置(resize)为 256×256,在训练中随机裁剪(crop)出 227×227。

2 实验结果与分析

2.1 数据集的建立与评价指标

本文实验数据来自国际标准心电数据库 MIT-BIH,该数据有准确全面的专家标注,被广泛使用于近年来的心电研究中^[19]。实验中训练集与测试集的样本大小如表 2 所示。训练迭代次数为 10 000,在一次迭代中,对一维数据集使用的小批量为 64,对二维

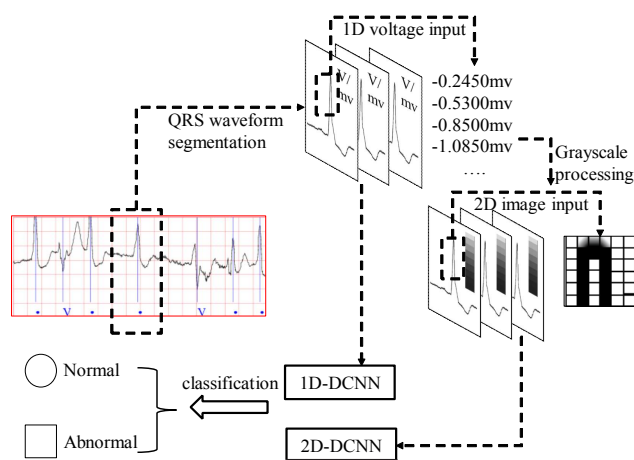


图2 本文算法流程图

Fig.2 Flowchart of the proposed algorithm

2D-DCNN: Two-dimensional deep convolution neural network; 1D-CNN: One-dimensional deep convolution neural network

数据集使用的小批量为128。在二维数据集中,为了进行数据扩充,以 227×227 为窗口大小对图像随机裁剪。实验采用5折交叉验证,取平均值作为最终结果。为了验证模型的鲁棒性,以高斯带限白噪声模拟肌电干扰^[20],对心电信号进行加噪处理。不同信噪比的心电信号如图3所示。所有实验基于深度学习框架Caffe^[21]。1D-CNN和2D-DCNN优化使用NVIDIA GeForce GTX 1080 GPU (VRAM 8GB)进行加速。

表2 训练和测试样本的数量
Tab.2 Number of training and testing samples

Signal type	Input size	Classification	Training	Testing
1D voltage	820	Normal	5 000	1 500
		Abnormal	5 000	1 500
2D image	227×227	Normal	5 000	1 500
		Abnormal	5 000	1 500

为了对二分类实验结果进行量化分析,实验使用常用评价指标:敏感度(Sen)、特异性(Spec)、准确率(Acc)。计算定义如下:

$$\text{Sen} = \frac{\text{TP}}{\text{TP} + \text{FN}} \times 100\% \quad (6)$$

$$\text{Spec} = \frac{\text{TN}}{\text{TN} + \text{FP}} \times 100\% \quad (7)$$

$$\text{Acc} = \frac{\text{TP} + \text{TN}}{\text{TN} + \text{FP} + \text{TP} + \text{FN}} \times 100\% \quad (8)$$

其中,TP表示将正常心电数据分类到正常类别,TN表示将异常数据分类到异常类别,TP和TN均表示分类准确;FP表示将异常心电数据分类到正常类别,




图3 心电图数据预处理

Fig.3 Electrocardiogram (ECG) data preprocessing

FN表示将正常数据分类到异常类别,FP和FN均表示分类错误^[23]。敏感度表示系统检测到的正常心电数据占总体正常数据的比例;特异性表示异常心电数据占总体异常数据的比例;准确率表示判定正确的数据在总体数据中的比例。3个指标可以从总体上反映系统整体分类能力,其值越大,说明分类效果越好。

2.2 不同激活函数在1D-CNN中的比较

如表3所示,本文比较了5种不同的激活函数,分别为tanh、ReLU、SeLU、ELU、以及Swish在相同1D-CNN下对心电分类的作用。Swish、ELU和ReLU的分类效果较好,准确率分别为96.00%、95.50%和95.40%。另外,Swish、ReLU以及tanh在不同信噪比的数据中保持着良好的鲁棒性,准确率下降差为1.3%、1.4%和1.9%。在5种激活函数中,Swish函数所对应的准确率和鲁棒性最好,从而证明Swish函数不仅适用于基于大规模数据集的大型深度学习网络^[18],也同样适用于一些小型网络,如本文的心电分类。因此,在一维数据输入的神经网络中,Swish激活函数能达到最佳的分类效果。

2.3 迁移学习对2D-DCNN的作用

采用在ImageNet数据集进行预训练得到的模型权值对本文AlexNet-like进行初始化。如表4所示,使用迁移学习后,敏感度、特异性与准确率分别为99.00%、96.50%和98.00%,均好于高斯随机初始化网络的96.67%、91.00%和94.40%,并且随着信噪比的降低,迁移学习后的网络准确率变化在1.25%范围之内,鲁棒性优于高斯随机初始化网络(见表3)。如图4所示为测试过程中迭代次数与准确率的关系曲线。从实验结果看出,迁移学习提高了2D-DCNN性能,减少了测试数据的误差,提高了分类准确率。

表 3 1D-CNN 和 2D-DCNN 在不同信噪比下的性能比较(%)

Tab.3 Comparison of 1D-CNN and 2D-DCNN at different signal-to-noise ratios (%)

Type	Signal-to-noise ratio				
	Original	35	30	25	20
tanh-1D	94.90	94.80	94.50	94.30	93.00
ELU-1D	95.50	95.10	94.90	93.70	92.90
SeLU-1D	94.40	93.80	93.50	92.00	91.60
ReLU-1D	95.40	95.30	94.80	94.50	94.00
Swish-1D	96.00	95.60	95.30	95.30	94.70
Random-2D	94.40	94.00	93.90	93.70	92.80
ImageNet-2D	98.00	97.50	97.00	96.75	96.75

表 4 不同网络的评价指标结果(%)

Tab.4 Evaluations of different networks (%)

Indicator	Swish-1D	ReLU-1D	Random-2D	ImageNet-2D
Sensitivity	98.33	98.16	96.67	99.00
Specificity	92.50	91.50	91.00	96.50
Accuracy	96.00	95.40	94.40	98.00




图 4 测试集准确率与迭代次数的关系曲线

Fig.4 Relationship between test accuracy and iterations

2.4 2D-DCNN 与 1D-CNN 的比较

如表 3 及表 4 所示,在高斯随机初始化的神经网络中,一维信号输入(ReLU-1D)的准确率和鲁棒性始终比二维网络(Random-2D)准确率高,这是因为一维模型的输入参数大小远远小于二维模型参数大小。参数更多、复杂度更高的模型,在数据量有限的情况下,更容易引起过拟合,使其泛化能力下降,从而分类精度降低。但使用迁移学习后,2D-DCNN 准

准确率超过了分类效果最好的一维网络(Swish-1D)准确率提升 2%、敏感度提升 0.6%、特异性提高了 4%。在对系统鲁棒性测试方面,随着信噪比的降低,测试样本的准确率都呈下降的趋势,说明噪声会对分类结果产生一定影响,相比之下,迁移学习后的二维网络受噪声干扰最小。

2.5 心电信号多分类

为了验证本文方法的通用性,将心电二分类问题拓展到多分类进行测试。MIT-BIH 数据库提供了 41 种疾病的标注信息,本文选取了其中的正常窦性心律、左束支传导性阻滞、右束支传导性阻滞、房性早搏和室性早搏共 5 类疾病作为分类类别。因为该 5 种疾病在心血管疾病中所占比较大,临床价值较高,且在 QRS 波形上具有明显的特异性^[24],作为图像输入更具有代表性和挑战性。将异常数据细分为 5 类异常疾病之后,本文将如图 1 所示的网络结构进行调整,来测试本文方法在心电识别多分类的效果。本文使用的 5 类数据来源如表 5 所示,测试结果准确率达 94.5%(如表 6 所示),好于近三年来其他深度学习方法,证明本文提出的结合 ImageNet 权值初始化的迁移学习方法和 2D-DCNN 具有良好的泛化性能。

表 5 多分类数据来源

Tab.5 Data source for multi-class classification

Annotation	Disease	Sample	Number
1	Normal	100.101.103.105.106	15 199
2	LBBB	109.111.214	6 094
3	RBBB	118.124.212.231	6 617
5	PAC	209.232.222	4 031
8	VPB	106.119.200.208.221.233	1 943

LBBB: Left bundle branch block; RBBB: Right bundle branch block; PAC: Premature atrial contraction; VPB: Ventricular premature beat

表 6 分类准确率比较

Tab.6 Comparison of classification accuracy

Classification	Methods	CNN setting	Accuracy/%
Binary	Acharya, et al ^[24]	c:4 p:4 fc:3	94.95
	Fujita, et al ^[25]	c:4 p:4 fc:3	95.22
	Proposed	c:5 p:3 fc:3	98.00
Five-class	Pyakillya, et al ^[8]	c:7 p:7 fc:3	86.00
	Zubair, et al ^[26]	c:3 p:3 mlp:1	92.70
	Proposed	c:4 p:4 fc:3	94.50

c: Convolution layer; p: Pooling layer; fc: Fully connected layer; mlp: Multilayer perceptron

3 结 语

本文对比了心电一维信号和二维图像输入在1D-CNN和2D-DCNN中分类效果。首先,在一维网络中,Swish激活函数较其它激活函数在心电分类中性能更好,具有更高的准确率和鲁棒性。接着,发现一维信号输入准确率与鲁棒性均强于二维图像输入后,引入ImageNet权值初始化,通过迁移学习的方法有效二维输入的过拟合问题,其测试准确率可达98%。相对于传统分类方法而言,2D-DCNN不需要手动提取特征;相对于1D-CNN而言,本文提出的2D-DCNN可以利用在ImageNet数据集上进行预训练的网络进行迁移学习,有效解决了心电分类图像样本数量不足的问题,在二分类与多分类系统中均达到了较高的分类准确率。本文提出的方法与现有自动分类相比有了较好的精度提升,证明了使用迁移学习有助于提高心电图图像的识别,在未来的研究中,将进一步扩充数据集,使用数据扩充的手段在已优化网络上提升分类准确率。

【参考文献】

- [1] YE C, COIMBRA M T, KUMAR B V. Arrhythmia detection and classification using morphological and dynamic features of ECG signals[C]//Annual International Conference of the IEEE Engineering in Medicine Biology Society. IEEE, 2010: 1918-1921.
- [2] 车宝真, 蔚承建, 万夕里, 等. 基于Spark平台的心电大数据分析处理[J]. 计算机工程与设计, 2018(1): 108-114.
CHE B Z, WEI C J, WAN X L, et al. Big data analysis and processing of ECG based on Spark platform [J]. Computer Engineering and Design, 2018(1): 108-114.
- [3] LUZ E J, SCHWARTZ W R, CAMARA-CHAVEZ G, et al. ECG-based heartbeat classification for arrhythmia detection: a survey[J]. Comput Methods Programs Biomed, 2016, 127: 144-164.
- [4] CLIFFORD G D, AZUAJE F, MCSHARRY P. Advanced methods and tools for ECG data analysis[M]. Boston, MA: Artech House, 2006: 67-69, 101-127.
- [5] PAN J, TOMPKINS W J. A real-time QRS detection algorithm[J]. IEEE Trans Biomed Eng, 1985, 32(3): 230-236.
- [6] 黄碧莹, 唐桦明, 钟能枝, 等. 基于多模板匹配的室性心动过速与室上性心动过速自动识别算法[J]. 中国医学物理学杂志, 2016, 33(3): 280-285.
HUANG B Y, TANG H M, ZHONG N Z, et al. Automatic identification algorithm based on multi-template matching for ventricular tachycardia and supraventricular tachycardia [J]. Chinese Journal of Medical Physics, 2016, 33(3): 280-285.
- [7] 袁野, 王夏天, 张子辰, 等. 基于小波变换和改进的瞬态独立成分分析融合算法的心电信号降噪方法[J]. 中国医学物理学杂志, 2016, 33(4): 415-422.
YUAN Y, WANG X T, ZHANG Z C, et al. Electrocardiogram noise reduction based on fused algorithm of wavelet transform and improved independent component analysis [J]. Chinese Journal of Medical Physics, 2016, 33(4): 415-422.
- [8] PYAKILLYA B, KAZACHENKO N, MIKHAILOVSKY N. Deep learning for ECG classification[J]. JPCS, 2017, 913(1): 012004.
- [9] KIRANYAZ S, INCE T, GABBOUJ M. Real-time patient-specific ECG classification by 1D convolutional neural networks[J]. IEEE Trans Biomed Eng, 2016, 63(3): 664-675.
- [10] 颜昊霖, 安勇, 王宏飞, 等. 基于卷积神经网络的心电特征提取[J]. 计算机工程与设计, 2017, 38(4): 1024-1028.
YAN H L, AN Y, WANG H F, et al. Feature extraction of ECG heartbeats based on convolutional neural networks [J]. Computer Engineering and Design, 2017, 38(4): 1024-1028.
- [11] WU Y, YANG F, LIU Y, et al. A comparison of 1-D and 2-D deep convolutional neural networks in ECG classification [C]//Annual International Conference of the IEEE Engineering in Medicine Biology Society. IEEE, 2018.
- [12] TAJBAKHSN N, SHIN J Y, GURUDU S R, et al. Convolutional neural networks for medical image analysis: full training or fine tuning?[J]. IEEE Trans Med Imaging, 2016, 35(5): 1299-1312.
- [13] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet classification with deep convolutional neural networks[C]//Advances on Neural Information Processing Systems. Curran Associates Inc., 2012: 1097-1105.
- [14] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [15] GLOROT X, BORDES A, BENGIO Y, et al. Deep sparse rectifier neural networks [C]//International Conference on Artificial Intelligence and Statistics. PMLR, 2011: 315-323.
- [16] KLAMBAUER G, UNTERTHINER T, MAYR A, et al. Self-normalizing neural networks[Z]. Preprint arXiv: 1706.02515, 2017.
- [17] RAMACHANDRAN P, ZOPH B, LE Q V. Searching for activation functions[Z]. Preprint arXiv: 1710.05941, 2017.
- [18] DENG J, DONG W, SOCHER R, et al. ImageNet: a large-scale hierarchical image database [C]//IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2009: 248-255.
- [19] MOODY G B, MARK R G. The impact of the MIT-BIH arrhythmia database[J]. IEEE Eng Med Biol Mag, 2002, 20(3): 45-50.
- [20] GOLDBERGER A L, AMARAL L A, GLASS L, et al. PhysioBank, PhysioToolkit, and PhysioNet: components of a new research resource for complex physiologic signals[J]. Circulation, 2000, 101(23): E215.
- [21] JIA Y, SHELHAMER E, DONAHUE J, et al. Caffe: convolutional architecture for fast feature embedding [C]. Proceedings of the 22nd ACM International Conference on Multimedia, 2014: 675-678.
- [22] HU Y, PALREDDY S, TOMPKINS W J. A patient-adaptable ECG beat classifier using a mixture of experts approach[J]. IEEE Trans Biomed Eng, 1997, 44(9): 891-900.
- [23] PLAWIAK P. Novel methodology of cardiac health recognition based on ECG signals and evolutionary-neural system[J]. Expert Syst Appl, 2018, 92: 334-349.
- [24] ACHARYA U R, FUJITA H, LIH O S, et al. Application of deep convolutional neural network for automated detection of myocardial infarction using ECG signals[J]. Inform Sci, 2017, 415: 190-198.
- [25] ACHARYA U R, FUJITA H, LIH O S, et al. Automated detection of coronary artery disease using different durations of ECG segments with convolutional neural network[J]. Knowledge-Based Systems, 2017, 132: 62-71.
- [26] ZUBAIR M, KIM J, YOON C. An automated ECG beat classification system using convolutional neural networks [C]//International Conference on IT Convergence and Security. IEEE, 2016: 1-5.

(编辑:薛泽玲)